Elementi di Bioinformatica

Gianluca Della Vedova

Univ. Milano-Bicocca https://gianluca.dellavedova.org

28 ottobre 2023

Pattern matching su suffix array

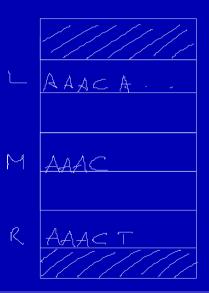
Occorrenza P in T

Suffissi di T che iniziano con P

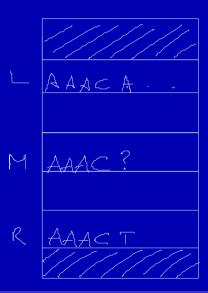
Ricerca in SA

- Ricerca dicotomica
- Tempo O(m log n) caso pessimo
- Controllare tutto P ad ogni iterazione
- log₂n iterazioni

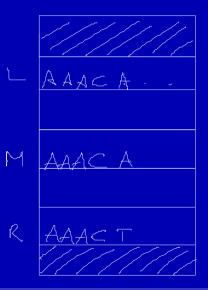
- Intervallo SA(L, R) di SA
- Elemento mediano M
- Tutti i suffissi in SA(L, R) iniziano con uno stesso prefisso lungo Lcp(SA[L], SA[R])
- Non confrontare con i primi Lcp(SA[L], SA[R]) caratteri



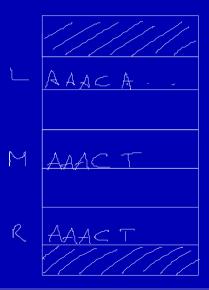
- Intervallo SA(L, R) di SA
- Elemento mediano M
- Tutti i suffissi in SA(L, R) iniziano con uno stesso prefisso lungo Lcp(SA[L], SA[R])
- Non confrontare con i primi Lcp(SA[L], SA[R]) caratteri



- Intervallo SA(L, R) di SA
- Elemento mediano M
- Tutti i suffissi in SA(L, R) iniziano con uno stesso prefisso lungo Lcp(SA[L], SA[R])
- Non confrontare con i primi Lcp(SA[L], SA[R]) caratteri

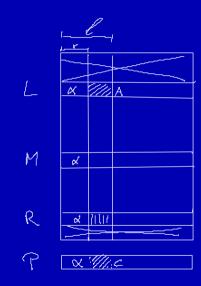


- Intervallo SA(L, R) di SA
- Elemento mediano M
- Tutti i suffissi in SA(L, R) iniziano con uno stesso prefisso lungo Lcp(SA[L], SA[R])
- Non confrontare con i primi Lcp(SA[L], SA[R]) caratteri



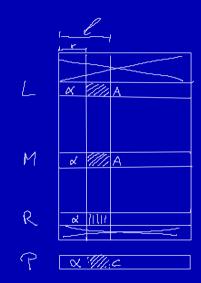
- Intervallo SA(L, R) di SA
- Elemento mediano M
- Tutti i suffissi in SA(L, R) iniziano con uno stesso prefisso lungo Lcp(SA[L], SA[R])
- Non confrontare con i primi Lcp(SA[L], SA[R]) caratteri



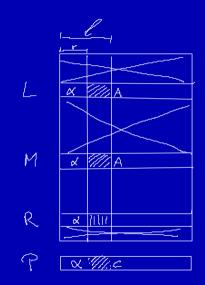


1: lcp(L, P); r: lcp(R, P)

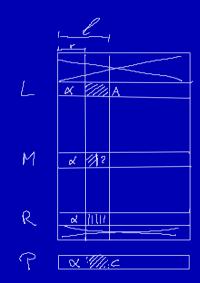
1 Caso 1: l > r



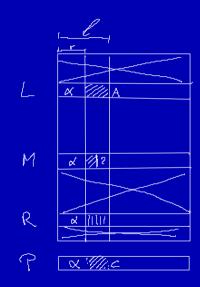
- 1 Caso 1: l > r
 - Lcp(L, M) > 1



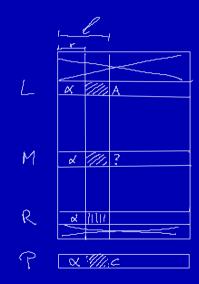
- 1 Caso 1: l > r



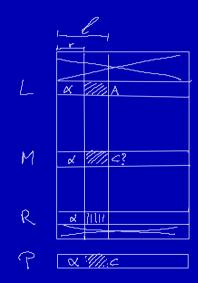
- 1 Caso 1: l > r
 - $Lcp(L, M) > l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < l



- 1 Caso 1: l > r
 - $Lcp(L, M) > l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < $l \Rightarrow$ R \leftarrow M, r \leftarrow Lcp(M, L)

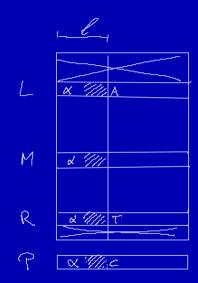


- 1 Caso 1: l > r
 - $Lcp(L, M) > l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < $l \Rightarrow$ R \leftarrow M, r \leftarrow Lcp(M, L)
 - Lcp(L, M) = l



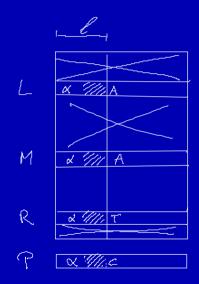
1: lep(L, P); τ : Lep(R, P)

- 1 Caso 1: l > r
 - $Lcp(L, M) > l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < $l \Rightarrow$ R \leftarrow M, r \leftarrow Lcp(M, L)
 - Lcp(L, M) = $l \Rightarrow$ confronto P[l + 1 :], M[l + 1 :]

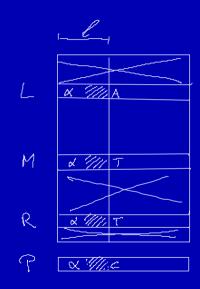


1: lep(L, P); τ : Lep(R, P)

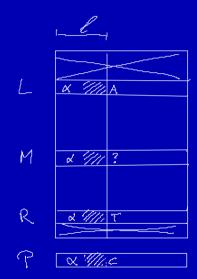
- 1 Caso 1: l > r
 - $Lcp(L, M) > l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < $l \Rightarrow$ R \leftarrow M, r \leftarrow Lcp(M, L)
 - Lcp(L, M) = $l \Rightarrow$ confronto P[l + 1 :], M[l + 1 :]
- 2 Caso 2: l = r



- 1 Caso 1: l > r
 - $Lcp(L, M) > l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < $l \Rightarrow$ R \leftleftharpoonup M, r \leftleftharpoonup Lcp(M, L)
 - Lcp(L, M) = $l \Rightarrow$ confronto P[l + 1 :], M[l + 1 :]
- **2** Caso 2: l = r
 - Lcp(L, M) > 1



- 1 Caso 1: l > r
 - $Lcp(L, M) > l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < $l \Rightarrow$ R \leftarrow M, r \leftarrow Lcp(M, L)
 - Lcp(L, M) = $l \Rightarrow$ confronto P[l + 1 :], M[l + 1 :]
- **2** Caso 2: l = r
 - Lcp(L, M) > l
 - Lcp(M, R) > 1



- 1 Caso 1: l > r
 - Lcp(L, M) > $l \Rightarrow L \leftarrow M$
 - Lcp(L, M) < $l \Rightarrow$ R \leftarrow M, r \leftarrow Lcp(M, L)
 - Lcp(L, M) = $l \Rightarrow$ confronto P[l + 1 :], M[l + 1 :]
- 2 Caso 2: l = r
 - Lcp(L, M) > 1
 - Lcp(M, R) > 1
 - Lcp(L, M) = Lcp(M, R) = l

Iterazione 1: (L, R) = (1, n)

- Iterazione 1: (L, R) = (1, n)
- Iterazione 2: (L, R) = (1, n/2) oppure (n/2, n)

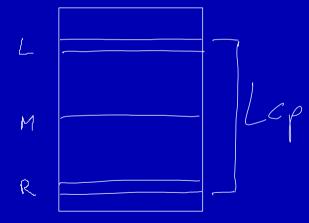
- Iterazione 1: (L, R) = (1, n)
- Iterazione 2: (L, R) = (1, n/2) oppure (n/2, n)
- Iterazione k: $L = h \frac{n}{2^{k-1}}$, $R = (h+1) \frac{n}{2^{k-1}}$

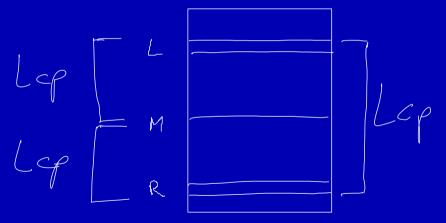
- Iterazione 1: (L, R) = (1, n)
- Iterazione 2: (L, R) = (1, n/2) oppure (n/2, n)
- Iterazione k: $L = h_{\frac{n}{2^{k-1}}}$, $R = (h+1)\frac{n}{2^{k-1}}$
- Iterazione $\lceil \log_2 n \rceil$: R = L + 1, Lcp(h, h + 1)

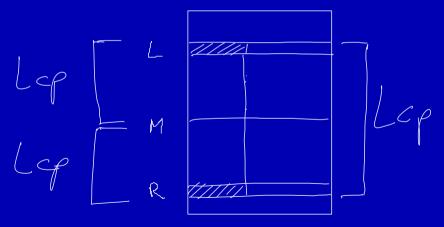
- Iterazione 1: (L, R) = (1, n)
- Iterazione 2: (L, R) = (1, n/2) oppure (n/2, n)
- Iterazione k: $L = h_{\frac{n}{2^{k-1}}}$, $R = (h+1)\frac{n}{2^{k-1}}$
- Iterazione $\lceil \log_2 n \rceil$: R = L + 1, Lcp(h, h + 1)
- Iterazione $\lceil \log_2 \mathfrak{n} \rceil 1$: aggrego i risultati dell'iterazione $\lceil \log_2 \mathfrak{n} \rceil$

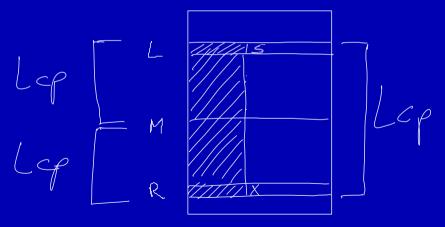
- Iterazione 1: (L, R) = (1, n)
- Iterazione 2: (L, R) = (1, n/2) oppure (n/2, n)
- Iterazione k: $L = h_{\frac{n}{2^{k-1}}}$, $R = (h+1)\frac{n}{2^{k-1}}$
- Iterazione $\lceil \log_2 n \rceil$: R = L + 1, Lcp(h, h + 1)
- Iterazione $\lceil \log_2 \mathfrak{n} \rceil$ 1: aggrego i risultati dell'iterazione $\lceil \log_2 \mathfrak{n} \rceil$
- Iterazione k: $Lcp(h\frac{n}{2^{k-1}}, (h+1)\frac{n}{2^{k-1}})$

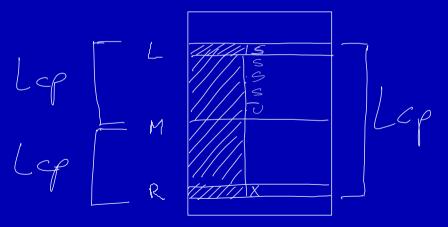
- Iterazione 1: (L, R) = (1, n)
- Iterazione 2: (L, R) = (1, n/2) oppure (n/2, n)
- Iterazione k: $L = h \frac{n}{2^{k-1}}$, $R = (h+1) \frac{n}{2^{k-1}}$
- Iterazione $\lceil \log_2 n \rceil$: R = L + 1, Lcp(h, h + 1)
- Iterazione $\lceil \log_2 n \rceil 1$: aggrego i risultati dell'iterazione $\lceil \log_2 n \rceil$
- Iterazione k: $Lcp(h\frac{n}{2^{k-1}}, (h+1)\frac{n}{2^{k-1}})$
- $t = \frac{n}{2^k}, Lcp(2ht + 1, (2h + 2)t)) = min\{ Lcp(2ht + 1, (2h + 1)t), Lcp((2h + 1)t + 1, (2h + 2)t), Lcp((2h + 1)t, (2h + 1)t + 1) \}$











Passaggio da s a z deve esistere

Osservazione

Tempo per trovare un'occorrenza

Osservazione

- Tempo per trovare un'occorrenza
- Tempo per trovare tutte le occorrenze?

Osservazione

- Tempo per trovare un'occorrenza
- Tempo per trovare tutte le occorrenze?
- O(n + m + k), per k occorrenze | scansione lineare a partire dall'occorrenza trovata

Costruzione suffix array: nuovo alfabeto

- Alfabeto Σ con σ simboli, testo T lungo n
- Aggrego triple di caratteri
- Alfabeto Σ^3 con σ^3 simboli, testo lungo $\pi/3$
- T₁ = (T[1], T[2], T[3]) ··· (T[3i + 1], T[3i + 2], T[3i + 3]) ··· T₂ = (T[2], T[3], T[4]) ··· (T[3i + 2], T[3i + 3], T[3i + 4]) ··· T₀ = (T[3], T[4], T[5]) ··· (T[3i], T[3i + 1], T[3i + 2]) ···
- ullet suffissi(T) $\Leftrightarrow \bigcup_{i=0,1,2} suffissi(T_i)$

Costruzione suffix array: ricorsione

- Ricorsione su T₀T₁
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_0), suffissi(T_1)

Costruzione suffix array: ricorsione

- Ricorsione su T₀T₁
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_0), suffissi(T_1)
- suffissi(T₀T₁) \Leftrightarrow suffissi(T₂)

- Ricorsione su T₀T₁
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_0), suffissi(T_1)
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_2)
- 1 $T_2[i:] \approx T[3i+2:]$

- Ricorsione su T₀T₁
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_0), suffissi(T_1)
- ightharpoonup suffissi(T₀T₁) \Leftrightarrow suffissi(T₂)
- 1 $T_2[i:] \approx T[3i+2:]$
- 2 $T[3i + 2:] = T[3i + 2]T[3i + 3:] = T[3i + 2]T_0[i + 1:]$

- Ricorsione su T₀T₁
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_0), suffissi(T_1)
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_2)
- 1 $T_2[i:] \approx T[3i+2:]$
- 2 $T[3i + 2:] = T[3i + 2]T[3i + 3:] = T[3i + 2]T_0[i + 1:]$
- **3** suffissi(T₀) ordinati

- Ricorsione su T₀T₁
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_0), suffissi(T_1)
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_2)
- 1 $T_2[i:] \approx T[3i+2:]$
- 2 $T[3i + 2:] = T[3i + 2]T[3i + 3:] = T[3i + 2]T_0[i + 1:]$
- $\mathbf{3}$ suffissi(T_0) ordinati
- 4 Radix sort

- Ricorsione su T₀T₁
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_0), suffissi(T_1)
- suffissi(T_0T_1) \Leftrightarrow suffissi(T_2)
- 1 $T_2[i:] \approx T[3i+2:]$
- 2 $T[3i + 2:] = T[3i + 2]T[3i + 3:] = T[3i + 2]T_0[i + 1:]$
- 3 suffissi(T_0) ordinati
- 4 Radix sort
- 5 Fusione suffissi(T_0T_1), suffissi(T_2)

Costruzione suffix array: fusione

Confronto suffisso di T₀ e T₂

- 1 $T_0[i:] <=> T_2[j:]$
- $T[3i:] \le T[3j+2:]$
- $T[3i]T[3i+1:] \le T[3j+2]T[3j+3:]$
- 4 $T[3i]T_1[i:] \le T[3j+2]T_0[j+1:]$

Costruzione suffix array: fusione

Confronto suffisso di T₁ e T₂

- 1 $T_1[i:] <=> T_2[j:]$
- $T[3i + 1 :] \le T[3j + 2 :]$
- $T[3i + 1]T[3i + 2:] \le T[3j + 2]T[3j + 3:]$
- T[3i + 1]T[3i + 2]T[3i + 3:] <=> T[3j + 2]T[3j + 3]T[3j + 4:]
- 5 $T[3i + 1]T[3i + 2]T_0[i + 1 :] \le T[3j + 2]T[3j + 3]T_1[j + 1 :]$

KS

- Juha Kärkkäinen, Peter Sanders and Stefan Burkhardt. Linear work suffix array construction. J. ACM, 53 (6), 2006, pp. 918-936.
- 2 Difference cover (DC) 3
- Stefan Burkhardt and Juha Kärkkäinen. Fast lightweight suffix array construction and checking In Proc. 14th Symposium on Combinatorial Pattern Matching (CPM '03), LNCS 2676, Springer, 2003, pp. 55-69. http://www.stefan-burkhardt.net/CODE/cpm_03.tar.gz
- 4 Yuta Mori. SAIS https://sites.google.com/site/yuta256/

k stringhe $\{s_1, \ldots, s_k\}$

1 Suffix tree generalizzato

- 1 Suffix tree generalizzato
- 2 Vettore $C_x[1:k]$ per ogni nodo x

- 1 Suffix tree generalizzato
- 2 Vettore $C_x[1:k]$ per ogni nodo x
- $C_x[i]$: sottoalbero con radice x ha una foglia di s_i

- 1 Suffix tree generalizzato
- **2** Vettore $C_x[1:k]$ per ogni nodo x
- $C_x[i]$: sottoalbero con radice x ha una foglia di s_i
- 4 $C_x = \bigvee C$ sui figli di C

- Suffix tree generalizzato
- 2 Vettore $C_x[1:k]$ per ogni nodo x
- $C_x[i]$: sottoalbero con radice x ha una foglia di s_i
- 4 $C_x = \bigvee C$ sui figli di C
- Nodo z, $C_z = \text{tutti } 1$

- Suffix tree generalizzato
- 2 Vettore $C_x[1:k]$ per ogni nodo x
- $C_x[i]$: sottoalbero con radice x ha una foglia di s_i
- 4 $C_x = \bigvee C$ sui figli di C
- Nodo z, $C_z = tutti 1$
- 6 Tempo O(kn)

- Suffix tree generalizzato
- 2 Vettore $C_x[1:k]$ per ogni nodo x
- $C_x[i]$: sottoalbero con radice x ha una foglia di s_i
- 4 $C_x = \bigvee C$ sui figli di C
- Nodo z, $C_z = tutti 1$
- 6 Tempo O(kn)
- 7 n: summa lunghezze $|s_1| + \cdots + |s_k|$

Lowest common ancestor (lca)

Dati albero T e 2 foglie x, y

- \mathbf{z} è antenato comune di \mathbf{x} , \mathbf{y} se \mathbf{z} è antenato di entrambi \mathbf{x} e \mathbf{y}
- z è lca di x, y se:
 - 1 z è antenato comune di x e y
 - 2 nessun discendente di z è antenato comune di x e y

Proprietà

- \blacksquare Preprocessing di T in tempo O(n)
- Calcolo lca(x, y) in tempo O(1)
- Algoritmo complesso, ma pratico

Arricchimento ST

 $1 N_x[i]$: numero foglie di s_i discendenti di x

- 1 $N_x[i]$: numero foglie di s_i discendenti di x
- $N_x[i] = 0$ o 1 per ogni foglia

- 1 $N_x[i]$: numero foglie di s_i discendenti di x
- $N_x[i] = 0$ o 1 per ogni foglia
- $N_x[i] = \text{somma dei figli}$

- 1 $N_x[i]$: numero foglie di s_i discendenti di x
- $N_x[i] = 0$ o 1 per ogni foglia
- $N_x[i] = \text{somma dei figli}$
- 4 $D_x[i]$: numero di consecutive di foglie di s_i , ordinate secondo visita depth-first, discendenti di x

- 1 $N_x[i]$: numero foglie di s_i discendenti di x
- $N_x[i] = 0$ o 1 per ogni foglia
- $N_x[i] = \text{somma dei figli}$
- 4 $D_x[i]$: numero di consecutive di foglie di s_i , ordinate secondo visita depth-first, discendenti di x
- $N_{x}[i] = 0 \Rightarrow D_{x}[i] = 0$

- 1 $N_x[i]$: numero foglie di s_i discendenti di x
- $N_x[i] = 0$ o 1 per ogni foglia
- $N_x[i] = \text{somma dei figli}$
- 4 $D_x[i]$: numero di consecutive di foglie di s_i , ordinate secondo visita depth-first, discendenti di x
- $N_{x}[i] = 0 \Rightarrow D_{x}[i] = 0$

- 1 $N_x[i]$: numero foglie di s_i discendenti di x
- $N_x[i] = 0$ o 1 per ogni foglia
- $N_x[i] = \text{somma dei figli}$
- 4 $D_x[i]$: numero di consecutive di foglie di s_i , ordinate secondo visita depth-first, discendenti di x
- 6 $N_x[i] = 1 \Rightarrow D_x[i] = 0$
- 7 $N_x[i] \geqslant 1 \Rightarrow D_x[i] = N_x[i] 1$

- 1 $N_x[i]$: numero foglie di s_i discendenti di x
- $N_x[i] = 0$ o 1 per ogni foglia
- $N_x[i] = \text{somma dei figli}$
- 4 $D_x[i]$: numero di consecutive di foglie di s_i , ordinate secondo visita depth-first, discendenti di x
- $N_{x}[i] = 0 \Rightarrow D_{x}[i] = 0$
- 6 $N_x[i] = 1 \Rightarrow D_x[i] = 0$
- 7 $N_x[i] \geqslant 1 \Rightarrow D_x[i] = N_x[i] 1$
- 8 $N_x[i] D_x[i] = C_x[i]$

Gestione ST

- Visita depth-first di ST
- L_i: lista ordinata delle foglie di s_i
- Per ogni coppia x, y consecutiva in Li
 - 1 $z \leftarrow lca(x, y)$
 - $D_z[i] =$
 - 3 Aggiorna C_z

Licenza d'uso

Quest'opera è soggetta alla licenza Creative Commons: Attribuzione-Condividi allo stesso modo 4.0. (https://creativecommons.org/licenses/by-sa/4.0/). Sei libero di riprodurre, distribuire, comunicare al pubblico, esporre in pubblico, rappresentare, eseguire, recitare e modificare quest'opera alle seguenti condizioni:

- Attribuzione Devi attribuire la paternità dell'opera nei modi indicati dall'autore o da chi ti ha dato l'opera in licenza e in modo tale da non suggerire che essi avallino te o il modo in cui tu usi l'opera.
- Condividi allo stesso modo Se alteri o trasformi quest'opera, o se la usi per crearne un'altra, puoi distribuire l'opera risultante solo con una licenza identica o equivalente a questa.